Data Engineering
Modularbeit – Aufgabenstellung (Teil 2)

Prof. Dr. Stephanie Thiemichen
Hochschule München

11. Juni 2025

Aufgabenstellung – Generelles / Hinweise

Erstellen Sie eine lauffähige Demo bzw. einen Prototypen entsprechend des Fokus-Themas der jeweiligen Gruppe. Zwecks Nachvollziehbarkeit und Reproduzierbarkeit ist ein gruppenspezifisches Gitlab-Verzeichnis zu verwenden. Es steht Ihnen frei, die Aufgabenstellung mittels Shiny auf Basis von R und / oder Python zu bearbeiten. Genauere Informationen zu den formalen Vorgaben finden Sie weiter unten unter "Formales".
Bei den nachfolgenden Aufgaben, die zu bearbeiten sind, haben Sie alle Freiheiten hinsichtlich Struktur und Reihenfolge der Beschreibung, Wahl der Ansätze, Visualisierungen, etc.. Beachten Sie dazu die Hinweise zur Bewertung.
Gehen Sie beim Erstellen Ihrer Demo bzw. Ihres Prototypen davon aus, dass sich das Ganze (vor allem auch die Dokumentationsaspekte) unter anderem auch an Ihre Projektpartner:innen richtet, die nicht über tiefgreifendes Wissen im Bereich Data Engineering verfügen, aber am Projekt beteiligt sind, sich in regelmäßigen Austausch mit Ihnen befinden und sehr an den späteren Ergebnissen interessiert sind. Sie sollten die wesentlichen Punkte also nachvollziehen können.

Achtung: Im Rahmen dieser Projektarbeit werden Sie an der ein oder anderen Stelle (vereinfachende) Annahmen treffen bzw. Funktionalitäten erst einmal ausklammern müssen. Dokumentieren Sie dies bitte entsprechend mit.

Versuchen Sie die Demo und Dokumentation nicht zu überladen, sondern konzentrieren Sie sich auf Kernaussagen, wesentliche Aspekte bzw. Probleme und deren Belege bzw. Illustration in Form von Metriken, Beispielen oder Visualisierungen und deren Beschreibung bzw. Behebung.
Code ist nach Bedarf und zur Gewährleistung von Nachvollziehbarkeit mit Kommentaren zu versehen.

Bewertung

In der Modularbeit können Sie maximal 100 Punkte (ohne Bonus) erreichen. Die Punktevergabe erfolgt dabei anhand von drei Kategorien:

Kategorie	Beispiele	Max. Punkte
Umsetzung	Korrektheit, Nachvollziehbarkeit und Reproduzierbarkeit der verwendeten gewählten Algorithmen / Ansätze / Visualisierungen	40
Beschreibung	Korrektheit und Verständlichkeit der Dokumentation	40
Stil	Sinnvolle Aufbereitung der Demo und Dokumentation hinsichtlich Sprache, Grafiken, Code (inklusive Kommentaren), Struktur, ...	20

Aufgabenstellung – Setting & Gruppen-Fokusthemen

Sie sind Teil eines größeren Projekt-Teams im Rahmen von HM-SENSE. Für alle Gruppen ist der generelle Fokus dieser Projektarbeit der Bereich Data Engineering. Im Speziellen sind folgende Fokusthemen zu bearbeiten:

G1 Wunsch des:r Data Scientist:in: Ergänzung der Daten um Wetterdaten (z.B. von `https://dwd.api.bund.dev/`). Beispielsweise zur Beurteilung extremer Raumtemperaturen sind Wetterdaten sehr wertvoll (z.B. zur Ausreißeranalyse bzw. Einordnung extremer Werte). Aus Data Science-Sicht wären die Wetterdaten in Form von zusätzlichen Spalten im Datensatz sehr nützlich.
Stakeholder:in: Data Scientist:in

G2 Fragen des:r Betreiber:in: Wie oft sind die Hörsäle außerhalb einer angenehmen Temperatur? Können wir feststellen, ob das durch Sonneneinstrahlung passiert (Lichtsensor?)? Gibt es Situationen, wo ein Hörsaal im Winter sehr kalt war, wo man vermuten kann, dass ein Fenster versehentlich offen gelassen wurde?
Stakeholder:in: Betreiber:in

G3 Fragen des:r Betreiber:in: In welchen Hörsälen sind die maximalen CO2-Werte vorgekommen? Was ist die größte beobachtete Steigung der CO2-Raten? Wie schnell können welche Hörsäle von dem Maximum wieder auf "gesunde" CO2-Dichten gelüftet werden? Welche Hörsäle können nicht gut gelüftet werden?
Können gezielt zusätzliche Messwerte, durch z.B. Experimente erhoben werden, um Lüftungsempfehlungen zu evaluieren?
Stakeholder:in: Betreiber:in

G4 Wunsch aus dem Bereich Betrieb der Sensorik: Reports bzw. Übersicht in Form eines Dashboards, welche Sensoren mit welcher Frequenz messen bzw. wann Frequenzen umgestellt wurden; Übersicht über Ausfallzeiten wegen Batteriewechse; potentielle Ausfälle, die nicht durch Batteriewechsel erklärbar sind. Wie sieht die Statistik des Batteriewechsels aus (Median, Mittel, ggf. Violin Plot?)?
Stakeholder:in: Betreiber:in

G5 Frage aus dem Bereich Data Science: Gibt es Hörsäle, die manchmal zu feucht oder zu trocken sind? Korreliert das mit zu geringer oder zu hoher Temperatur? Gibt es Hörsäle, die als extrem auffallen und wenn ja, inwiefern?
Stakeholder:in: Data Scientist:in

G6 Wunsch des:r Data Scientist:in: Dashboard zur Übersicht der Datenqualität je Sensor und je Raum. Möglichkeit Daten direkt als CSV zu exportieren (Auswahl Frequenz, Transformation auf equidistante Zeitpunkte, Selektion Spalten).
Stakeholder:in: Data Scientist:in

Die Fokusthemen der Gruppen sind so zu verstehen, dass Sie sich damit auf jeden Fall auseinander setzen sollen. Weitere Aspekte können, am besten nach Rücksprache, natürlich trotzdem betrachtet werden.

Aufgabe 1 (Überblick Datenformat & Transformation)

Verschaffen Sie sich zunächst einen Überblick über die bereit stehenden Daten.
Im Moodle finden Sie dafür eine ZIP-Datei mit Beispieldaten im CSV-Format.
Die benötigten Zugangsdaten für die InfluxDB Instanz finden Sie in einer YAML-Konfigurationsdatei im Moodle[1].
Gibt es Probleme bzw. Dinge, die Ihnen auffallen? Dokumentieren Sie diese und versuchen Sie sie möglichst pragmatisch zu lösen.

Aufgabe 2 (Entwicklungstagebuch & Aufgabenverteilung)

Erstellen Sie ein Entwicklungstagebuch im Markdown-Format, was die Ziele der aktuellen Projektphase stichpunktartig festhält. Auf die Ziele müssen sich als Gruppe natürlich verständigen.
Beschreiben Sie hier auch Ihr Vorgehen (Plan vs. Realität) über die Entwicklungszeit und wichtige Erkenntnisse auf dem Weg zum fertigen Prototypen (z.B. auch Fehlschläge in der Wahl des Ansatzes etc.).
Es ist festzuhalten, wer (namentlich) an welchem Teil mitgearbeitet hat und wer jeweils verantwortlich war.
Tipp: Planen Sie jede Woche gezielt entsprechend Zeit für die Aktualisierung / Fortführung des Entwicklungstagebuches ein.

Aufgabe 3 (Shiny App)

Zweck der App bzw. des Prototypen ist es, bestehende Probleme bzw. implementierte Ansätze im Bereich Ihres Fokusthemas möglichst anschaulich zu illustrieren bzw. diese zu dokumentieren. Sie sind als Team frei im Aufbau der App (z.B. Anzahl Tabs, Nutzer:innenführung, etc.), allerdings sollten Sie das Ganze nicht überladen. Priorisieren Sie Funktionalitäten und arbeiten Sie diese nach und nach ab.

Aufgabe 4 (Stake-Holder:innen-Gespräch 25.06. – Vorbereitung & Protokoll)

Bereiten Sie das gruppenweise Gespräch (Dauer maximal 30 Minuten) mit dem:r jeweiligen Stakeholder:in vor, indem Sie Fragen bereits vorab notieren.
Ihre Aufgabe wird es sein, kurz (ca. 5 bis maximal 10 Minuten) Ihren aktuellen Stand zu präsentieren (kann auch ein Konzept bzw. eine Idee sein zu dem Zeitpunkt) und im Anschluss daran, Ihre Fragen im Gespräch zu klären.
Das Gespräch (vor allem wesentliche Punkte und Erkenntnisse) ist im Markdown-Format zu protokollieren und im Git-Verzeischnis als `Stake_protokoll.md` mit abzulegen.

[1] Diese bitte nicht unter Versionskontrolle stellen.

Aufgabe 5 (Dokumentation: README.md)

Der README-File soll zu Beginn eine kurz stichpunktartige Management-Summary[2] enthalten, in der die wesentlichen Aspekte (v.a. Zweck und Ansatz) und Funktionalitäten des Prototypen / der Demo kurz zusammen gefasst werden.
Des Weiteren soll der README-File einen groben Überblick über die Verzeichnis-Struktur des Git-Verzeichnisses beinhalten zur Orientierung.
Im letzten Abschnitt des README-Files ist eine Schritt-für-Schritt-Anleitung der Demo / des Porotypen zu intergrieren (z.B. mit Beschreibung / Screenshots / ...).
Weitere Dokumentationsabschnitte können Sie in den File intergrieren, sofern Sie es für sinnvoll erachten.

Formales – Abgabemodalitäten

Technische Aspekte:

- Aktivitäten im Gitlab müssen konkreten Personen aus den jeweiligen Gruppen zugeordnet werden können. Verwenden Sie daher bitte Ihre Klarnamen in den Gitlab-Profilen.
- Beschränken Sie sich bei den verwendeten Paketen in R auf Pakete, die via CRAN (Standard) verfügbar sind, und in Python auf Pakete, die via conda oder pip / PyPi verfügbar sind[3].
- Die Demo kann auf den zur Verfügung gestellten Testdaten, einer entsprechenden Abfrage an die Live-Datenbank oder einer selbst erzeugten Datendatei (Bitte Größe beachten!) basieren. Bei Letzterem sind die verwendeten Skripte zwecks Reproduzierbarkeit ins Git-Verzeichnis zu intergrieren und das Ganze ist im README-File entsprechend zu vermerken.

Achtung: Die Demo / der Prototyp in Shiny muss ohne weitere Anpassungen - nach Installation der benötigten Pakete - in einer aktuellen R- (Version $>$ 4.0.0) oder Python-Umgebung (Version $>$ 3.10) auf einem anderen System als dem Ihren ausführbar sein. Die Modularbeit wird andernfalls mit **nicht bestanden** bewertet.

[2] siehe z.B. `https://de.wikipedia.org/wiki/Executive_Summary`
[3] Ausnahmen nur nach Rücksprache möglich!

Verzeichnis-Struktur:

Ihr Git-Repository sollte (mindestens) folgende Elemente beinhalten:

i. Ordner `data`: (Optionales) Verzeichnis, das sämtliche verwendete Datenfiles (z.B. als `.csv`-Dateien) enthält.

ii. Ordner `shiny`: Verzeichnis, das die benötigten Code-Files für die Shiny-App beinhaltet.

iii. `README.md`: *siehe oben.*

iv. `Entwicklungstagebuch.md`: *siehe oben.*

v. `Stake_protokoll.md`: *siehe oben.*

vi. Zusätzlich umgebungsabhängig

R `setup_install.R`: Eine R-Datei, die die Installationsbefehle (über `install.packages()`) der von Ihnen zusätzlich zur Basis-Installation verwendeten Pakete enthält.

Python `setup_requirements.txt`: Spezifizieren Sie hier bitte die von Ihnen verwendeten Python-Packages inklusive deren Versionen, sowie die verwendete Python Version selbst.

Abgabefrist

Erstellen Sie am Ende nach dem finalen Commit auf den Master-Branch Ihres Gruppen-Gitverzeichnisses eine gezipte Version des Verzeichnisses als `[Gitlab Repo Name].zip`.
Reichen Sie das ZIP-Archiv via Moodle als Gruppe ein.

Frist: **Donnerstag, 10.07.2025 bis 23:59 Uhr**.